



DESAFÍO DE CLASIFICACIÓN

Predicción de Abandono de Clientes

ABC Multistate Bank

Un modelo de Machine Learning para anticipar la fuga de clientes y orientar la retención.

Integrantes: Angello Avellaneda · Francisco Cariaga · Sebastián Rodríguez · Álvaro Vergara · Vicente Yáñez

Profesor: Francisco Alfaro **Asignatura:** Analítica para los Negocios I **Fecha:** 30 de junio de 2026

El problema de negocio



El problema

Cada vez más clientes cierran sus cuentas. El churn golpea por partida doble: se pierde el ingreso del cliente y se gasta más en captar uno nuevo.



Por qué importa

Retener es mucho más barato que captar. Si detectamos las señales de fuga a tiempo, el banco puede actuar antes de perder al cliente.



Objetivo

Construir y comparar modelos que predigan qué clientes abandonarán, entender qué factores influyen y proponer acciones de retención.

El dataset de un vistazo

10.000

clientes

12

variables

20,4%

tasa de churn

0

nulos / duplicados

Las variables combinan información de tres tipos:

Demográficas

edad, género, país

Financieras

puntaje crediticio, saldo, salario estimado

Relación con el banco

antigüedad, n° productos, tarjeta, actividad

La variable objetivo churn está desbalanceada (1:4) → la accuracy no sirve; usamos ROC-AUC, recall, precisión y F1.

El hallazgo más importante

El número de productos manda


Relación fuertemente no lineal.

Con 2 productos el churn es mínimo (~7,5%), pero con 3 o 4 se dispara a 82%–100%.





¿Qué significa para el negocio?

Es un síntoma de fricción operativa o de venta cruzada (cross-selling) agresiva que termina generando insatisfacción y fuga.

Churn según número de productos



¿Quién se va? Segmentos de riesgo



● **Alemania:** 32% de churn vs ~16% en Francia y España

● **Mujeres:** 25% frente a 16% en hombres

● **Inactivos:** 27% — casi el doble que los activos (14%)

● **Mayor edad:** los que se van promedian 44,8 años vs 37,4

Dejar los datos listos para modelar



Codificación

One-Hot Encoding en country y gender (drop_first para evitar multicolinealidad). Se elimina customer_id.



Escalado

StandardScaler en las numéricas (media 0, desv. 1), ajustado solo con train para evitar fuga de datos.



Split estratificado

80% train / 20% test, manteniendo la proporción de churn (~20%) en ambos conjuntos.



Desbalance

class_weight='balanced' en vez de SMOTE: penaliza más fallar en la clase minoritaria sin inventar datos.

Cuatro modelos, una misma métrica (ROC-AUC)

BASELINE

Regresión Logística

Simple e interpretable. Sus coeficientes se leen como probabilidad de churn.

NO LINEAL

Árbol de Decisión

Capta relaciones que la regresión no ve. max_depth=6, hojas mín. 10.

ENSEMBLE

Random Forest

500 árboles que votan: menos varianza, más robustez. max_depth=12.


SECUENCIAL

Gradient Boosting

Cada árbol corrige al anterior. lr=0.03, depth=3, 300 árboles, subsample=0.8.

Todos ajustados con validación cruzada. ¿Por qué Boosting suele ganar? Construye en secuencia, enfocándose en los casos difíciles → capta interacciones complejas con menos sesgo.


¿Cuál discrimina mejor?



Modelo	ROC-AUC	Prec.	Recall	F1
Gradient Boosting	0.872	0.80	0.50	0.61
Random Forest	0.864	0.61	0.65	0.63
Árbol de Decisión	0.841	0.45	0.78	0.57
Reg. Logística	0.777	0.39	0.70	0.50

Gradient Boosting lidera el ROC-AUC (0.872) — la métrica principal — y tiene la mayor precisión.

Modelo elegido: Gradient Boosting



Matrices de confusión de los cuatro modelos (umbral 0.5)

Mejor ROC-AUC

0.872, el más alto


Mayor precisión

~80% de aciertos al alertar

Margen de mejora

su recall sube al calibrar umbral

Mover el umbral cambia el juego



El 0.5 rara vez es lo óptimo

Buscamos el umbral que maximiza F1 → 0.25.

Umbral	Prec.	Recall	F1
0.20	0.51	0.77	0.61
0.25 (óptimo)	0.59	0.71	0.64
0.50	0.80	0.50	0.61
0.70	0.91	0.34	0.49

Bajar el umbral sube el Recall (detectamos más fugas) a costa de Precisión. El 0.25 equilibra ambos.

¿Recall o Precisión? La decisión de negocio

Falso negativo

Decir que se queda... y se va.

El banco pierde al cliente y todo su valor futuro, más el alto costo de captar un reemplazo.

→ El error **MÁS caro**

Falso positivo


Alertar de alguien que se quedaba.

Solo cuesta una acción de retención: una llamada o un pequeño incentivo. Gasto acotado.

→ El error **más barato**

Conclusión: para ABC Bank conviene priorizar el **Recall** → operar con umbral 0.25 captura más clientes en riesgo real.

Los factores que más pesan



~38%

Edad
El factor determinante. Segmento mayor (44,8 años) con propensión drásticamente superior.

~29%

N° de productos
2 productos = máxima fidelidad (7,5%); 3-4 = abandono crítico (82-100%).

~11%

Actividad
Los inactivos abandonan al doble de velocidad que los activos.

—

Saldo y geografía
Cuentas fondeadas y clientes de Alemania: riesgo secundario relevante.

Acciones concretas de retención



Segmento senior

Atención preferencial para mayores de 40: interfaz simple, asesoría humana, productos de protección patrimonial.



Auditoría de sobreventa

Frenar cross-selling agresivo sobre quienes ya tienen 2 productos; equipo de retención para los de 3+.



Campaña de engagement

Alerta si el cliente no transacciona en 30 días → comunicación con beneficios de uso (cashback).



Mercado alemán

Benchmarking contra competidores locales para ajustar tasas y oferta de valor.

META

Reducir el churn 10% el próximo trimestre

1

Scoring mensual

Pasar toda la base por el modelo con umbral calibrado y marcar la zona de riesgo.

2

Priorizar riesgo × valor

Cruzar probabilidad de churn con saldo/salario; atacar primero Alto Riesgo–Alto Valor.

3

Pruebas A/B

Campañas al 80% en riesgo y 20% de control para medir la retención real lograda.

4

Monitoreo de ROI

Comparar costo de incentivos vs. capital retenido (lifetime value recuperado).

Del modelo a la acción: integrar el score en el CRM (alerta automática si churn > 30%) y reentrenar con el feedback de cada campaña.



DESAFÍO DE CLASIFICACIÓN

Predicción de Abandono de Clientes

ABC Multistate Bank

Un modelo de Machine Learning para anticipar la fuga de clientes y orientar la retención.

Integrantes: Angello Avellaneda · Francisco Cariaga · Sebastián Rodríguez · Álvaro Vergara · Vicente Yáñez

Profesor: Francisco Alfaro **Asignatura:** Analítica para los Negocios I **Fecha:** 30 de junio de 2026